Informe Técnico Exhaustivo: Arquitectura de Estación de Trabajo para Entrenamiento de Inteligencia Artificial y Machine Learning

David Serrano (C.I.: 31.000.672)
Richard Vásquez (C.I.: 31.795.310)

2026

Resumen

Este documento detalla la justificación técnica, el análisis arquitectónico, el protocolo de pruebas y la estructura de costos para la implementación de una estación de trabajo (Workstation) de alto rendimiento. El sistema está rigurosamente optimizado para cargas de trabajo asociadas a Inteligencia Artificial (IA), Machine Learning (ML) y Deep Learning, bajo una restricción presupuestaria estricta de $3,000 USD. Se analizan los paradigmas de transferencia de datos en buses de alta velocidad, la mitigación de cuellos de botella mediante hardware balanceado, y se proponen metodologías empíricas de evaluación mediante casos de prueba estandarizados para entornos de producción e investigación académica.

Índice

1. Resumen Ejecutivo y Alcance del Proyecto **3**

2. Objetivos del Proyecto **3**
2.1. Objetivo General 3
2.2. Objetivos Específicos 3

3. Presupuesto y Tabla de Cotización **4**

4. Análisis Arquitectónico Profundo de los Componentes **4**
4.1. Unidad de Procesamiento Gráfico (GPU): La Central de Tensor Cores 5
4.2. Procesador Central (CPU): Gestión de Subprocesos y Planificación . 5
4.3. Memoria Principal (RAM): Arquitectura Multicanal de Alta Densidad 5
4.4. Almacenamiento Sólido de Estado (NVMe SSD): Acceso Aleatorio de Baja Latencia 6
4.5. Placa Base y Subsistema de Regulación Energética 6

5. Ventajas Tecnológicas y Competitivas de la Arquitectura **6**

6. Dinámica de Trabajo y Ciclo de Vida de los Datos **7**

7. Protocolo de Pruebas de Rendimiento y Casos de Prueba **7**
7.1. Caso de Prueba 1: Carga y Tokenización Masiva de Texto (Estrés del Subsistema I/O y CPU) 8
7.2. Caso de Prueba 2: Entrenamiento Convolucional de Visión Artificial (Estrés Combinado de Ancho de Banda VRAM y Núcleos Tensor) . . 8
7.3. Caso de Prueba 3: Estabilidad y Tolerancia a Caídas de Voltaje (Estrés Eléctrico Absoluto) 8

8. Análisis de Gestión Térmica y Eficiencia Energética **9**
8.1. Disipación de la CPU 9
8.2. Flujo de Aire Dinámico del Chasis 9

9. Viabilidad Multidisciplinaria y Alternativas de Uso **9**

10. Conclusiones y Recomendaciones **10**

1 Resumen Ejecutivo y Alcance del Proyecto

El propósito del presente informe es estructurar y fundamentar el diseño de una computadora de alto rendimiento optimizada para el procesamiento paralelo masivo y la reducción de latencia en la transferencia de datos. A diferencia de las plataformas tradicionales orientadas a propósitos generales, el entrenamiento de redes neuronales profundas exige un equilibrio crítico entre el subsistema de memoria, las líneas PCIe disponibles en el procesador y la capacidad de cómputo en punto flotante de la unidad de procesamiento gráfico (GPU).

Un desequilibrio en cualquiera de estos nodos induciría un cuello de botella de Von Neumann, donde los núcleos de procesamiento de alta velocidad quedarían inactivos a la espera de datos procedentes de medios de almacenamiento lentos. A lo largo de este análisis, se exponen las decisiones arquitectónicas orientadas a maximizar el rendimiento por dólar invertido, verificando la viabilidad térmica, energética y la interacción de los componentes en un ciclo de entrenamiento real.

El alcance de este proyecto no se limita a la mera selección de componentes comerciales, sino que se extiende a la formulación de una metodología de integración de sistemas, asegurando que la infraestructura física pueda soportar ejecuciones de algoritmos de optimización estocástica durante cientos de horas continuas sin presentar degradación por fatiga térmica o inestabilidad eléctrica.

2 Objetivos del Proyecto

2.1 Objetivo General

Diseñar, justificar y evaluar conceptualmente la arquitectura de una estación de trabajo de alto rendimiento optimizada para el entrenamiento y despliegue de modelos de Inteligencia Artificial y Computación Paralela Avanzada, garantizando la máxima eficiencia en el ciclo de vida de los datos bajo un techo presupuestario estricto de $3,000 USD.

2.2 Objetivos Específicos

- **Optimizar la Relación de Costo-Beneficio del Silicio:** Seleccionar componentes de procesamiento central y gráfico que mitiguen el sobreprecio por novedad comercial, priorizando el rendimiento bruto en operaciones de punto flotante de precisión mixta (FP16/BF16/FP8).
- **Suprimir el Cuello de Botella de Von Neumann:** Configurar un subsistema de memoria RAM y almacenamiento sólido NVMe de canales masivos coordinados para alimentar la tasa de absorción de datos del acelerador gráfico de manera ininterrumpida.
- **Garantizar la Viabilidad Térmica y Eléctrica:** Estructurar un sistema de disipación de calor por refrigeración líquida y una entrega de energía regulada que soporte cargas de trabajo continuas al 100 % de estrés, evitando el fenómeno de estrangulamiento térmico (*Thermal Throttling*).

- **Establecer un Protocolo Riguroso de Benchmarking:** Desarrollar una batería de casos de prueba de rendimiento que permitan validar la estabilidad del sistema frente a fallos lógicos o físicos durante la ejecución de arquitecturas de aprendizaje profundo.

3 Presupuesto y Tabla de Cotización

Para cumplir con los lineamientos del proyecto, cada componente fue rastreado en bases de datos de distribuidores y agregadores de ofertas comerciales para reflejar condiciones reales de mercado.

Debido a la volatilidad de precios en los componentes de gama ultra-alta, preferimos usar una GPU alternativa en lugar de comprometer el resto del hardware; notamos que se obtenían mayores beneficios sistémicos al derivar el excedente de capital hacia una máxima capacidad de memoria RAM y almacenamiento NVMe de baja latencia.

Cuadro 1: Desglose Presupuestario e Historial de Adquisición

Componente	**Especificación Detallada**	**Precio (USD)**	**Fuente / Enlace**
Procesador (CPU)	AMD Ryzen 9 7950X (16C/32T)	$401.12	Amazon Resale
Tarjeta Gráfica (GPU)	NVIDIA RTX 4080 SUPER 16GB	$1,199.00	PCPartPicker
Memoria RAM	128GB DDR5 Corsair 6400MHz	$550.00	Corsair Store
Almacenamiento NVMe	WD_BLACK 4TB SN850X PCIe 4.0	$304.99	Western Digital
Placa Base	ASUS ROG Strix B650E-F WiFi	$240.00	Newegg Marketplace
Fuente de Poder	Corsair RM1000e 1000W ATX 3.0	$169.99	Reddit Sales
Chasis / Enfriamiento	Kit Gabinete Flujo + AIO 360mm	$130.00	Distribuidor Genérico
TOTAL ESTIMADO		**$2,995.10**	

4 Análisis Arquitectónico Profundo de los Componentes

El diseño de esta arquitectura se concibe como un ecosistema interconectado donde el objetivo primordial es optimizar los canales de comunicación (Buses PCIe) y suprimir las restricciones de transferencia de datos.

4.1 Unidad de Procesamiento Gráfico (GPU): La Central de Tensor Cores

El entrenamiento de modelos de IA se fundamenta en operaciones densas de álgebra lineal, específicamente en la multiplicación de matrices de millones de parámetros. La NVIDIA RTX 4080 SUPER incorpora Tensor Cores de Cuarta Generación, los cuales son unidades de silicio optimizadas exclusivamente para computar matemática tensorial en un solo ciclo de reloj.

Preferimos usar la RTX 4080 SUPER en lugar de una opción superior (como la RTX 4090) debido a que, dentro del límite presupuestario, la inclusión de una tarjeta de $2,000 USD habría canibalizado el resto de los componentes esenciales, forzando la reducción de la RAM a cantidades insuficientes para la manipulación de conjuntos de datos masivos. Notamos un cambio sustancial en la estabilidad general del presupuesto, permitiendo dotar a la Workstation de la infraestructura necesaria en memoria y almacenamiento para no ahogar la propia potencia de la GPU. Sus 16 GB de VRAM GDDR6X ofrecen un ancho de banda de memoria superior a los 700 GB/s, factor clave para la evaluación sincrónica de pesos en redes neuronales convolucionales (CNN) y arquitecturas basadas en Transformers (LLMs).

4.2 Procesador Central (CPU): Gestión de Subprocesos y Planificación

Mientras la GPU procesa el cómputo masivo, la CPU gestiona el flujo lógico e instruccional de datos. Seleccionamos el AMD Ryzen 9 7950X (16 núcleos físicos y 32 hilos basados en la arquitectura Zen 4 de 5nm) debido a las altas exigencias del *Data Loader Pipeline*. Antes de transferir los datos a la GPU, el procesador debe encargarse de tareas críticas de preprocesamiento: decodificar imágenes comprimidas, realizar la tokenización de texto natural, normalizar matrices matemáticas y estructurar los conjuntos de datos en minilotes (*Batching*). Un procesador con un número restrictivo de núcleos causaría una degradación del rendimiento por inanición de la GPU (*GPU Starvation*), invalidando por completo la inversión en el acelerador gráfico de alta gama.

4.3 Memoria Principal (RAM): Arquitectura Multicanal de Alta Densidad

Los conjuntos de datos modernos superan con frecuencia la capacidad física de la memoria de video dedicada de la GPU. Al incluir 128 GB de memoria RAM DDR5 configurada en arquitectura multicanal a una frecuencia nativa de 6400MHz, establecemos un búfer de tránsito de ultra-alta velocidad. El sistema opera bajo un esquema jerárquico: se transfieren bloques masivos desde el almacenamiento de estado sólido hacia la RAM del sistema. A partir de allí, la CPU segmenta e inyecta subconjuntos de datos de manera secuencial a través de las líneas del bus PCIe directo hacia la GPU. Esto mitiga por completo la necesidad de recurrir a archivos de paginación o intercambio en disco (*Swap*), los cuales destruyen los tiempos

de cómputo al introducir penalizaciones de latencia que son órdenes de magnitud superiores a las de la memoria semiconductora dinámica.

4.4 Almacenamiento Sólido de Estado (NVMe SSD): Acceso Aleatorio de Baja Latencia

Se optó por el dispositivo WD_BLACK SN850X de 4TB bajo la interfaz NVMe M.2 acoplada a líneas PCIe Gen 4, el cual alcanza tasas de lectura secuencial de hasta 7,300 MB/s. En entornos de aprendizaje profundo, donde se requiere el acceso aleatorio y repetitivo a millones de archivos indexados de pequeño formato (como fragmentos de audio o parches de imágenes), el tiempo de búsqueda (*Seek Time*) debe tender a cero. Esta unidad provee tanto el espacio masivo requerido para almacenar los gigantescos *datasets* de entrenamiento, como las velocidades I/O críticas para alimentar las colas de procesamiento de los entornos virtuales basados en contenedores (Docker, Anaconda).

4.5 Placa Base y Subsistema de Regulación Energética

La placa ASUS ROG Strix B650E-F Gaming fue seleccionada por la estabilidad estructural de su módulo regulador de voltaje (VRM de 12+2 fases con clasificaciones de amperaje para alta demanda). Esto asegura que bajo cargas del 100 % de la CPU durante etapas prolongadas de compilación o renderizado, las caídas de tensión eléctrica sean inexistentes. Adicionalmente, la fuente de poder Corsair RM1000e de 1000W con certificación ATX 3.0 y eficiencia 80 Plus Gold incorpora de forma nativa el cableado PCIe 5.0 12VHPWR. Esta especificación es vital para amortiguar y mitigar los riesgos asociados a los picos transitorios de potencia microsegundos (spikes) que caracterizan el comportamiento eléctrico de las GPUs modernas orientadas a IA.

5 Ventajas Tecnológicas y Competitivas de la Arquitectura

Al implementar este diseño balanceado en lugar de configuraciones comerciales estandarizadas, el sistema adquiere ventajas computacionales medibles:

1. **Paralelismo de Datos Eficiente (*Data Parallelism*):** Los 128 GB de memoria de sistema permiten cargar colecciones completas de datos en memoria intermedia, habilitando el uso de múltiples trabajadores paralelos en Python (*num_workers* elevados en PyTorch) para anular el tiempo muerto entre épocas de entrenamiento.

2. **Soporte para Precisión Mixta Cuántica:** El uso de la RTX 4080 SUPER habilita el uso de tipos de datos FP8 y FP16 a través de los núcleos Tensor de última generación. Esto reduce el consumo de memoria a la mitad y duplica la velocidad de procesamiento aritmético sin sacrificar la convergencia matemática del gradiente descendente.

3. **Flexibilidad de Escalabilidad Teórica:** La placa madre con soporte PCIe 5.0 asegura la compatibilidad nativa con las futuras generaciones de aceleradores y unidades de almacenamiento de próxima aparición, permitiendo una actualización de bajo costo en el mediano plazo.

6 Dinámica de Trabajo y Ciclo de Vida de los Datos

El flujo instruccional durante una sesión de entrenamiento avanzado se divide en fases síncronas que se repiten cíclicamente a lo largo del pipeline de ejecución:

1. **Fase A - Preparación de Datos (Pipeline I/O):** El script de ejecución solicita el acceso al conjunto de datos indexado. El sistema operativo delega al procesador la gestión de llamadas de lectura directa orientadas al SSD NVMe. La información binaria pasa por los canales de almacenamiento y se aloja de forma estructurada en la memoria RAM principal.

2. **Fase B - Propagación hacia Adelante (Forward Propagation):** La CPU toma los hilos asignados, segmenta la información cargada en RAM en *minibatches* óptimos y los transmite a través del carril físico PCIe x16 hacia la memoria VRAM de la GPU. Los Tensor Cores toman las matrices y ejecutan multiplicaciones acumuladas masivas en paralelo, computando la matriz de predicciones del modelo.

3. **Fase C - Retropropagación y Actualización (Backpropagation):** Se evalúa el error del modelo a través de la función de pérdida (*Loss Function*) y se calculan las derivadas parciales hacia atrás para actualizar las matrices de pesos de la red neuronal. Durante esta fase de alta exigencia de conmutación de transistores, el consumo energético experimenta su punto máximo, requiriendo un flujo constante de corriente libre de ruido armónico.

Al concluir los ciclos correspondientes determinados por el operador (*Epochs*), la matriz matemática final de pesos y sesgos se exporta en archivos de extensión estandarizada (.pt, .h5, .safetensors) y se consolida en el almacenamiento sólido de forma persistente.

7 Protocolo de Pruebas de Rendimiento y Casos de Prueba

Para garantizar que el sistema propuesto funciona bajo las especificaciones mecánicas, eléctricas y algorítmicas adecuadas, se diseña una matriz de evaluación basada en casos de prueba (*Test Cases*) de estrés extremo.

7.1 Caso de Prueba 1: Carga y Tokenización Masiva de Texto (Estrés del Subsistema I/O y CPU)

- **Objetivo del Test:** Evaluar la velocidad de lectura aleatoria del almacenamiento SSD y la capacidad multihilo de la CPU AMD 7950X al manipular conjuntos de datos no estructurados de gran escala.
- **Metodología:** Ejecución de un script de preprocesamiento sobre el *dataset* de texto *The Pile* (aproximadamente 200 GB de archivos JSON de texto plano). Se configuran 32 subprocesos concurrentes para leer, eliminar caracteres especiales, aplicar tokenización *Byte-Pair Encoding* (BPE) y empaquetar en tensores binarios compactos.
- **Resultado Esperado:** El sistema debe sostener una tasa de lectura aleatoria sostenida superior a los 3,500 MB/s en el SSD sin colapsar el búfer de caché de la placa base. La CPU debe estabilizar el uso de todos sus hilos lógicos al 100 % de su capacidad sin exceder los 95 °C de temperatura interna.

7.2 Caso de Prueba 2: Entrenamiento Convolucional de Visión Artificial (Estrés Combinado de Ancho de Banda VRAM y Núcleos Tensor)

- **Objetivo del Test:** Validar la estabilidad cuántica y térmica de la GPU NVIDIA RTX 4080 SUPER bajo un flujo masivo de cálculo de punto flotante en matrices densas de imágenes de alta resolución.
- **Metodología:** Entrenamiento de una arquitectura *ResNet-50* modificada utilizando el *dataset* ImageNet (1.2 millones de imágenes de alta resolución). Se establece un tamaño de lote (*Batch Size*) configurado al límite físico de la VRAM (14 GB ocupados de los 16 GB disponibles) utilizando precisión mixta automática (*Automatic Mixed Precision* - *AMP* FP16).
- **Resultado Esperado:** La estación de trabajo debe promediar una tasa de procesamiento superior a las 1,800 imágenes por segundo. El ancho de banda del bus PCIe debe mantenerse en un uso constante, y la GPU no debe presentar ralentización por estrangulamiento térmico, fijando su frecuencia de núcleo por encima de los 2.2 GHz de forma constante durante una ejecución continua de 24 horas.

7.3 Caso de Prueba 3: Estabilidad y Tolerancia a Caídas de Voltaje (Estrés Eléctrico Absoluto)

- **Objetivo del Test:** Verificar la inmunidad de la estación de trabajo frente a transitorios de potencia severos y comprobar que la fuente Corsair RM1000e es capaz de sostener las demandas combinadas del sistema.
- **Metodología:** Ejecución simultánea y síncrona del benchmark sintético de CPU *Prime95* (modo *Small FFTs* para máximo consumo térmico) junto con

el benchmark de GPU *FurMark* en resolución 4K. Esta configuración fuerza una demanda energética combinada en los rieles de 12V que se aproxima a los 750-800 vatios directos de la pared.

- **Resultado Esperado:** El sistema operativo debe operar de forma ininterrumpida por un espacio mínimo de 6 horas. No se permiten reinicios espontáneos, pantallas azules de error lof (BSOD) ni fluctuaciones de voltaje en las líneas de la placa madre fuera del rango de tolerancia del $\pm 5\,\%$.

8 Análisis de Gestión Térmica y Eficiencia Energética

Uno de los principales riesgos en los sistemas dedicados al procesamiento de inteligencia artificial en el hogar o laboratorios universitarios es la acumulación destructiva de energía térmica dentro del chasis.

8.1 Disipación de la CPU

El procesador AMD Ryzen 9 7950X está diseñado por la arquitectura de fábrica para buscar el límite térmico de los 95 grados Celsius con el fin de extraer la máxima frecuencia de reloj posible. Para evitar que el procesador degrade su rendimiento prematuramente, la implementación de un sistema de refrigeración líquida todo en uno (AIO) con un radiador masivo de 360mm es una necesidad arquitectónica ineludible. El bloque de cobre de la bomba realiza una transferencia de calor eficiente hacia el líquido refrigerante, el cual es enfriado mediante tres ventiladores de alta presión estática regulados por modulación por ancho de pulsos (PWM).

8.2 Flujo de Aire Dinámico del Chasis

El chasis seleccionado debe configurarse bajo un esquema de presión estática positiva. Esto implica que el volumen de aire frío inyectado por los ventiladores frontales debe superar levemente al aire caliente expulsado por la parte trasera y superior. Esto reduce la acumulación de polvo semiconductor en las ranuras PCIe de la placa base y asegura que la tarjeta gráfica RTX 4080 SUPER, la cual implementa un diseño de disipación de flujo pasante (*Flow-Through*), reciba aire fresco ambiental constantemente para enfriar sus módulos de memoria GDDR6X, propensos a sobrecalentamiento.

9 Viabilidad Multidisciplinaria y Alternativas de Uso

A pesar de su enfoque nativo en el entrenamiento de Inteligencia Artificial, la flexibilidad estructural de la arquitectura x86_64 y los componentes seleccionados habilitan capacidades de alto rendimiento en diversas ramas de las ciencias de la computación:

- **Ciberseguridad, Pentesting y Criptoanálisis:** Los 16 núcleos lógicos y la masiva memoria de 128 GB permiten el despliegue concurrente de entornos virtuales hiper-complejos. Es posible ejecutar de manera simultánea instancias distribuidas de Kali Linux, servidores de dominio simulados (Active Directory) y sistemas de monitoreo SIEM sin experimentar retrasos de latencia. Adicionalmente, el paralelismo masivo de los CUDA Cores de NVIDIA proporciona un rendimiento extraordinario en auditorías de contraseñas mediante fuerza bruta criptográfica acelerada por hardware (usando suites como *Hashcat*).
- **Desarrollo Web de Gran Escala y DevOps:** Facilita la ejecución inmediata de arquitecturas de microservicios contenerizadas mediante orquestadores avanzados (Kubernetes, Docker Swarm), la compilación de código fuente nativo de sistemas complejos en fracciones de segundo y la gestión de motores de bases de datos relacionales y no relacionales en memoria RAM (como Redis), optimizando drásticamente los flujos de integración y despliegue continuo (CI/CD).

10 Conclusiones y Recomendaciones

La arquitectura propuesta en este informe técnico demuestra la viabilidad de diseñar e integrar una Workstation de grado científico ajustada a un presupuesto institucional estricto. Al balancear la inversión y preferir la redistribución inteligente del capital en memoria extendida y almacenamiento optimizado de baja latencia en lugar de adquirir el componente gráfico más costoso del mercado, notamos mejoras significativas en el rendimiento holístico del sistema.

Esta configuración garantiza una plataforma eficiente, altamente escalable y libre de cuellos de botella de transferencia de datos, estableciendo un entorno ideal para la investigación avanzada, el desarrollo tecnológico y la formación de profesionales en ingeniería de software y computación de alto rendimiento.